

가짜연구소 12기 스터디 · 민정

# Full-duplex 음성 AI, 해보니까 이렇더라

Realtime voice AI

TML

barge-in

AEC

Korean speech

# “Full-duplex 음성 AI는 모델만의 문제가 아니라 시스템 전체의 문제다.”

## 모델이 흡수하는 것

turn-taking, interruption, 감정  
이해,  
tool call 중 presence 유지

## 여전히 남는 것

마이크 · 스피커 · 배터리 · 비용  
latency · privacy · gate

## 현실적 결론

큰 realtime 모델  
+ 하드웨어 가까운 작은 gate 모델  
들

# 왜 지금 Full-duplex인가

"빨라진 음성 챗봇"이 아니라, 대화 방식 자체가 바뀌고 있다.

1. problem

## 기존 음성 챗봇

① 사용자가 말을 마친다



② STT로 텍스트 변환



③ LLM이 답변 생성



④ TTS가 읽어준다



⑤ 사용자 다시 말한다

VS

## Full-duplex

 말하는 중에도 계속 듣기

 짧게 backchannel로 반응

 끼어들지 말지 실시간 판단


 상대 상태를 200ms마다 추적

 turn-taking, interruption 내재화

# Cascaded Pipeline의 한계

1. problem

STT → LLM → TTS는 명확하지만, 대화의 미묘한 신호가 중간에서 사라진다.



**Latency**

각 단계마다 지연 누적

**Prosody loss**

억양·감정 강도 압축·손실

**Paralinguistic**

망설임·웃음·숨 등 사라짐

**Interruption**

끼어들기 상태 관리 어려움

# 음성 AI 지형도

2. landscape

현재 접근은 하나의 정답이 아니라 스펙트럼으로 봐야 한다.



# 모델 Survey: 세 갈래로 보기

2. landscape

상용 API, 오픈 모델, 연구 접근이 동시에 빠르게 진화 중이다.

## 상용 API

### GPT-Realtime-2

semantic\_vad · tool call · long context reasoning · production voice agent

### Gemini Live 3.1 Flash

low latency · tonal understanding · noisy 환경 강조 · function calling

## 오픈 모델

### Moshi (Kyutai)

full-duplex E2E · 12.5Hz codec · ~200ms practical latency

### Qwen3/3.5-Omni

Apache 2.0 · Thinker-Talker MoE · 256k context · ARIA streaming · 10개 언어

## 연구 접근

### DuplexCascade

VAD-free cascade · micro-turn · LLM control token으로 timing 제어

### TML-Interaction-Small

encoder-free early fusion · 200ms chunk · 276B MoE · dual-model 구조

"Interactivity should scale  
with intelligence,  
not be bolted on."


인터랙티비티는 외부 컴포넌트로 덧붙이는 게 아니라, 모델이 학습해야 한다.

- ① VAD, endpointing, barge-in policy → 모델 바깥 harness에서 모델 내부로
- ② 오디오를 텍스트로 바꾼 뒤 이해하는 방식 탈피 → 음성 자체를 직접 처리
- ③ 200ms 청크마다 상태 판단 → 말하는 중에도 계속 업데이트

# TML Architecture 한 장 요약

3. TML


음성·영상·텍스트를 처음부터 같이 보고, 200ms 단위로 계속 반응한다.





# 200ms Chunk의 의미

"말이 끝난 뒤 반응"이 아니라, 말하는 중에도 매 200ms마다 상태를 업데이트한다.



💡 매 200ms마다 안정적으로 추론해야 해서, serving 비용과 엔지니어링 난도가 함께 올라간다.

# TML 성능 수치와 주의점

3. TML

수치는 인상적이지만, closed preview라 외부 검증이 제한된다.

276B

MoE 파라미터

12B active params  
(실제 추론 시)

77.8

FD-bench v1.5

vs GPT-R2: 46.8  
vs Gemini Live: 54.3

0.40s

Turn latency


instant 설정 기준  
(non-thinking)

43.4%

Audio MultiChallenge

명령 이해 · 지식  
audio 추론

## FD-bench v1.5 비교



## ⚠️ 주의사항

- Closed preview → 외부 재현 불가
- Instant/non-thinking 설정 기준 (reasoning 켜면 지능 ↑, latency ↑)
- Long session context 관리 미해결
- 서버 비용 · scaling이 제품 병목 가능

# 모델이 똑똑해지면, 정말 주변 시스템은 사라질까?

4부. 실제로 만들면?

AEC

VAD

wake word

battery

latency

routing

privacy

safety


GPU cost

background  
speech

fallback

# 실제 제품의 입력단

모델은 "무엇을 들을지"부터 결정해야 한다. 모든 오디오를 frontier model로 보내면 비용과 privacy가 무너진다.



💡 작은 gate 모델들의 품질이 UX와 비용을 동시에 결정한다. 큰 모델 이전에 이 단계가 먼저 잘 돼야 한다.

실제 마이크에 들어오는 것:

사용자 목소리

TV 소리

가족 대화

혼잣말

배경 소음

# Wake Word는 사라질까?

UX만 보면 없애고 싶지만, 제품에서는 비용·배터리·privacy가 붙는다.

## ✗ Always-on Frontier Model

### 장점

- ✓ wake word 불필요
- ✓ 자연스러운 대화 시작
- ✓ 더 자연스러운 UX

### 단점

- ✗ 비용 폭발
- ✗ 배터리 소모 큼
- ✗ privacy 부담 (항상 전송)
- ✗ false positive 비용 높음

## ✓ Small Gate + Frontier on Demand

### 장점

- ✓ 배터리 효율적
- ✓ 비용 제어 가능
- ✓ privacy 보호
- ✓ 온디바이스 처리


### 단점

- ✗ gate 오픈 시 UX 깨짐
- ✗ wake word/trigger 설계 필요
- ✗ latency 추가 가능

결론: Wake word는 "사라진다"기보다 더 넓은 gate 모델로 재해석될 가능성이 크다.

# AEC: Full-duplex의 물리 문제

AI가 말하는 동시에 사용자를 들어야 한다 → 스피커 소리가 마이크로 돌아온다.



## 엔지니어링 챌린지

- Reference signal 동기화 (clock drift)
- 비선형 왜곡 처리 (스피커 왜곡)
- 잔향 / 룸 어쿠스틱
- 적용 위치: 디바이스 / OS / 앱 / 모델?
- WebRTC AEC3가 사실상 표준
- AEC 이후: VAD · 발화 종료 판단이 더 큰 과제

# VAD의 역설

Turn 종료 판단기로서 VAD는 위험하다. 하지만 비용 gate로서 VAD는 여전히 필요하다.

## ✗ 나쁜 사용: Turn 종료 판단

- 침묵 threshold로 발화 끝 판단
- "아... [침묵] ...그러니까" 같은 경우 오판
- 시니어/비원어민의 긴 호흡 패턴에 맞지 않음
- 생각 중인 침묵 ≠ 발화 종료

## ✓ 좋은 사용: Cost/Battery Gate

- 음성 활성화 감지 → 업로드 시작 여부 결정
- 배터리 소모 최소화
- 네트워크 비용 절감
- privacy 보호 (침묵 구간 전송 차단)

## semantic\_vad (OpenAI Realtime API)

침묵 기반 오판을 줄이기 위해 발화 내용을 의미적으로 분석 → end-of-turn 추정

eagerness 파라미터로 더 빨리 / 더 오래 기다릴지 조절 가능. 단, 어떤 소리를 보낼지 정하는 gate 문제는 여전히 남는다.

# 실패 사례: 침묵은 끝이 아니다

시나리오: 시니어 케어 companion



"아... 그러니까... [3초 침묵] ...어제 손주가..."

✗ 단순 VAD (silence threshold)

침묵 3초 → 턴 종료 판단 → AI가 끼어든다

✓ semantic VAD

"그러니까" + 침묵 → 말이 이어질 가능성 높음 → 기다린다

## semantic VAD로 완화해도 여전히 남는 문제



TV 소리

사용자와 TV 음성이 겹치면  
VAD가 활성화됨



가족 대화

옆에 다른 사람이 말할 때 모델  
로 전송할 것인지?



혼잣말

AI에게 하는 말인지, 독백인지  
구분 어려움



도메인 말버릇

시니어의 "그... 저... 음..." 필러  
처리 정책 필요



# Barge-in과 Backchannel

"응", "어", "그래"는 끼어들음이 아니다. 소리를 들었다는 사실보다 그 의도를 해석하는 게 어렵다.



## Backchannel

"응... 맞아... 그리고..."

의미:

대화 유지 신호  
(듣고 있음, 계속해도 돼)

AI: 계속 말하기



## Interruption

"잠깐만요, 그게 아니라..."

의미:

발화 교체 요청  
(상대 말 끊고 싶음)

AI: 즉시 멈추기 + 상태 롤백



## Correction

"아니, 제가 말하려는 건..."


의미:

이전 발화 정정  
(잘못 이해됨을 고침)

AI: 멈추고 재해석

# 출력단도 어렵다

Streaming TTS는 빨라야 하지만, 너무 앞만 보고 말하면 운율이 깨진다.



## ⚡ First byte latency

첫 토큰 → 첫 오디오까지 얼마나?  
token 충분히 쌓인 뒤 시작 vs 즉시 시작 trade-off

## 🎵 Prosody consistency

앞 문맥만 보고 운율 결정 →  
뒷 내용 알게 되면 이미 늦음 → 어색한 억양

## 🔄 Interruption recovery

사용자가 끊은 시점 이후  
"AI가 말했지만 사용자는 못 들은" 부분 처리

## 📝 Context handling

끊긴 발화를 컨텍스트에  
"말한 것"으로 남길지 말지 결정 필요

# Cost & Routing

모든 오디오를 frontier realtime model로 보내면 제품 원가가 무너진다.

## On-device Small Gate

\$

wake word · VAD  
배터리 최소화 · privacy

## Edge / 저가 서버 모델

\$\$

1차 routing · intent  
분류 · safety

## Frontier Realtime Model

\$\$\$

고품질 interaction · tool call  
긴 컨텍스트 추론

## Routing 결정 기준

대화인가?

→ Frontier model로

TV 소리 / 혼잣말?

→ 무시 (gate 차단)

단순 intent?

→ 저가 모델 처리

Safety 위험?

→ safety gate

Fallback 필요?

→ 작은 모델로 최소 UX



작은 gate 모델의 품질이 UX와 원가를 동시에 결정한다.

# 감정 표현은 왜 어려운가

감정을 읽는 것보다 어떤 톤으로 반응할지 정하는 것이 훨씬 어렵다.

## "괜찮으세요?"

같은 문장, 다른 톤 → 완전히 다른 상호작용

### 따뜻한 위로

부드러운 하강 억양  
낮은 속도, 살짝 끌어내림

✓ 자연스러움

### 형식적 확인

평탄한 억양  
중간 속도, 기계적 리듬

△ 어색한 느낌

### 추궁하는 듯한 톤

상승 억양  
빠른 속도, 강세 강화

✗ 불쾌감 유발

### 과도하게 다정

과장된 억양  
너무 천천히, 반복 강조

✗ 과잉 다정

# 한국어 Full-duplex, 무엇이 부족한가

ASR·TTS 데이터와 벤치마크는 늘고 있다. Full-duplex interaction 데이터와 평가가 비어있다.

## ASR / TTS

✓ 데이터 있음

- CoreaSpeech (700h · 21,449명)
- KsponSpeech (자연 발화 ASR)
- 숫자·영어 차용어 전처리 이슈 대응
- TTS 벤치마크 다수

## SpeechLM 평가

△ 등장 중

- KVoiceBench
- KOpenAudioBench
- KMMAU
- Spoken QA · audio understanding 중심


## Full-duplex Interaction

x 거의 없음

- Overlap · backchannel 데이터
- Turn-taking 평가 표준
- 시니어 발화 스타일 데이터
- 도메인별 필러·말버릇 데이터

# 미래 구조: 계층형 아키텍처

"하나의 거대한 모델"이 아니라, 큰 realtime 모델 + 하드웨어 가까운 작은 gate 모델들.



### 01 Interactivity는 모델 안으로 들어간다

Turn-taking, interruption, backchannel, 감정 이해는 점점 큰 interaction model이 직접 처리. harness는 줄어든다.

### 02 Gate는 하드웨어 가까이에 남는다

AEC, VAD, wake word, routing, safety, fallback은 모델만으로 사라지지 않는다. 작은 gate 모델들이 비용·배터리·privacy를 담당.

### 03 한국어 full-duplex는 데이터와 평가가 먼저

모델이 나오기를 기다리는 것만이 아니라, overlap·backchannel·시니어 발화 데이터와 평가셋을 같이 만들어야 한다.

# Q&A

Full-duplex 음성 AI,  
어디까지 모델이 먹고  
어디부터 시스템이 남을까?

semantic\_vad로 VAD 문제는 해결?

Cascaded는 정말 죽었나?

한국어 full-duplex 뭐부터?

작은 gate 모델은 꼭 필요한가?